Anteproyecto – Estimación de la presión arterial sistólica y diastólica a partir de señales PPG y ECG mediante aprendizaje profundo

Asignatura: SI7011 — Aprendizaje Profundo - Universidad EAFIT

Profesor: Juan David Martínez Vargas

Estudiante: Andres Felipe Agudelo Ortega **Asesor:** Daniel Sanín Villa – Universidad EAFIT

Programa: Maestría en Ciencias de la Ingeniería **Fecha:** 23 de octubre de 2026

---

1. Contexto y justificación

La hipertensión arterial (HTA) figura entre los factores de riesgo modificables de mayor incidencia en la morbimortalidad cardiovascular a nivel mundial. Un estudio 2010 estimó su prevalencia en el 31,1% de la población adulta, constituyendo un factor de riesgo clave para enfermedades cardiovasculares y mortalidad prematura [1]. La proporción de personas con esta condición es aproximadamente de un 75% en regiones de ingresos medios y bajos [1]. En Colombia, estudios epidemiológicos reportan prevalencias de 27.6% en adultos, con una proporción de 34.3% de personas de no saber que tenían esta condición [2]. Esta condición se ve agravada por desigualdades socioeconómicas estructurales que restringen el acceso a servicios de salud especializados y al seguimiento continuo de enfermedades crónicas.

En la práctica clínica, la presión arterial (PA) se mide con esfigmomanómetros de manguito oclusivo, que entregan mediciones discretas [4]. Cada toma exige inflar y desinflar el manguito y seguir un protocolo de reposo, por lo que no captura la variabilidad de la PA a lo largo del día ni durante las actividades cotidianas. El monitoreo ambulatorio de 24 horas (MAPA) amplía la observación fuera del consultorio, pero sigue siendo intermitente, con lecturas cada 15 a 60 minutos, y no mide durante el movimiento activo.

En este contexto, los sistemas que proporcionen una estimación continua y no invasiva de la PA, denominados en la literatura como métodos cuffless, constituyen una línea de desarrollo tecnológico con alto potencial de impacto en salud pública [3, 5]. Estos sistemas integran sensores fisiológicos portables con algoritmos de procesamiento de señal y modelos predictivos, con el objetivo de estimar la PA en tiempo real sin interrumpir las actividades del usuario [5]. Su aplicación en escenarios de baja complejidad asistencial, seguimiento ambulatorio en hogares o en comunidades con acceso limitado al sistema de salud, resulta particularmente pertinente para el contexto colombiano.

2. Problema y pregunta de investigación

Frente a la medición con manguito, que es intermitente [7], y al catéter intraarterial, que es invasivo [8], [9], una alternativa es estimar la PA de forma continua a partir de señales fáciles de adquirir, como el PPG y el ECG: la morfología del pulso refleja el estado vascular.

> **Pregunta:** ¿Qué combinación de señales de entrada (PPG, ECG o PPG + ECG) y qué arquitectura de aprendizaje profundo (MLP, GRU o ajuste fino del modelo fundacional TimesFM) estiman con menor error absoluto la presión arterial sistólica y diastólica en pacientes no vistos durante el entrenamiento, usando la base de datos MIMIC-BP?

3. Objetivos

General. Determinar qué combinación con las entradas (PPG, ECG, PPG + ECG) y qué arquitectura (MLP, GRU, Fine-Tuning de TimesFM) estiman con menor MAE la PAS y la PAD en pacientes no vistos de MIMIC-BP.

Específicos.

1. Construir un flujo de datos reproducible con partición por paciente y controles contra fugas de

información.

2. Entrenar las 9 combinaciones (3 entradas × 3 arquitecturas) con el mismo presupuesto de entrenamiento.
3. Evaluar las 9 combinaciones por paciente en el conjunto de prueba, comparando sus predicciones con la mediana de PAS y PAD de cada segmento entregada por MIMIC-BP, mediante MAE, ME y DE del error.

4. Datos disponibles

MIMIC-BP [11] es un subconjunto curado del *MIMIC-III Waveform Database Matched Subset* [12]: 1.524 pacientes de cuidado intensivo, cada uno con 30 segmentos de 30 s de ABP, PPG de dedo y ECG (derivación II). En total se dispone de 1.524 × 30 = 45.720 segmentos individuales, cada uno etiquetado con la mediana de la PAS y la PAD del segmento.

5. Acceso a los datos

Dataset: Harvard Dataverse, doi: 10.7910/DVN/DBM1NF (ppg, ecg, abp y labels; ≈ 680 MB comprimidos).

6. Metodología

Diseño factorial de 3 entradas × 3 arquitecturas, con el mismo flujo de datos, la misma partición y el mismo presupuesto de entrenamiento, implementado en PyTorch sobre Google Colab con el toolkit del curso:

- **Datos:** cada muestra es un segmento de 30 s (fs = 125 Hz): sus 3.750 valores por señal son la entrada directa del modelo y la mediana de PAS y PAD es la etiqueta. Se hace una partición aleatoria por paciente de 60 / 20 / 20 con semilla fija: 914 / 305 / 305 pacientes (27.420 / 9.150 / 9.150 segmentos), sin pacientes compartidos entre conjuntos. Dado que MIMIC-BP entrega las formas de onda extraídas directamente de MIMIC-III sin filtrado en frecuencia [11], cada señal se acondiciona con un filtro Butterworth pasa-banda de 4.º orden de fase cero (0,5–8 Hz para PPG y 0,5–40 Hz para ECG) con el fin de eliminar la deriva de línea base inducida por la respiración (< 0,5 Hz) y el ruido fuera de banda sin alterar el desfase temporal entre canales (PTT). Posteriormente, se aplica la estandarización de las entradas vista en S02, $x' = (x - \text{mean}(x)) / \text{std}(x)$, calculada de forma independiente por señal dentro de cada segmento de 30 s (normalización por instancia), corrigiendo variaciones de amplitud entre registros sin introducir fuga de información entre conjuntos. El conjunto de prueba se usa una sola vez.
- **Modelos:** MLP, GRU y ajuste fino (Fine-Tuning) de TimesFM (modelo fundacional preentrenado de Google para series de tiempo). Cada modelo se entrena con las tres entradas: PPG (1 canal), ECG (1 canal) y PPG + ECG (2 canales).
- **Salida y función de costo:** el problema se plantea como una regresión. Cada modelo termina en una capa lineal de 2 neuronas que entrega directamente la PAS y la PAD del segmento (mmHg). La función de costo es el error cuadrático medio (MSE) sobre las dos salidas, con las etiquetas estandarizadas con la media y la DE de entrenamiento para que ambas pesen igual.
- **Evaluación por paciente:** para cada uno de los 305 pacientes de prueba se comparan las predicciones de sus 30 segmentos con las medianas de PAS y PAD de MIMIC-BP y se calculan el MAE, el ME y la DE del error. Para cada combinación se reporta el promedio de las tres métricas sobre los pacientes de prueba.

7. Resultados esperados y entregables

- Notebook ejecutado en PyTorch (datos → modelo → entrenamiento → evaluación), con las corridas visibles.
- Documento de análisis con la tabla comparativa de las 9 combinaciones (3 entradas × 3 arquitecturas), con MAE, ME y DE por paciente para PAS y PAD

8. Referencias

[1] K. T. Mills, A. Stefanescu, and J. He, “The global epidemiology of hypertension,” *Nature Reviews Nephrology*, vol. 16, no. 4, pp. 223–237, 2020.

[2] Lopez-Lopez et al., “May Measurement Month 2022: an analysis of blood pressure screening results from Colombia,” *European Heart Journal Supplements*, vol. 27, suppl. 7, pp. vii23–vii26, 2025.

[3] M. Kachuee, M. M. Kiani, H. Mohammadzade, and M. Shabany, “Cuffless blood pressure estimation algorithms for continuous health-care monitoring,” *IEEE Transactions on Biomedical Engineering*, vol. 64, no. 4, pp. 859–869, 2017.

[4] K. Sel, D. Osman, N. Huerta, et al., “Continuous cuffless blood pressure monitoring with a wearable ring bioimpedance device,” *npj Digital Medicine*, vol. 6, no. 59, 2023.

[5] J. Hua, M. Su, J. Wu, et al., “Wearable cuffless blood pressure monitoring: From flexible electronics to machine learning,” *Wearable Electronics*, vol. 1, pp. 78–90, 2024.

[6] R. Mukkamala, G. S. Stergiou, and A. P. Avolio, “Cuffless blood pressure measurement,” *Annual Review of Biomedical Engineering*, vol. 24, pp. 203–230, 2022.

[7] J.-R. Hu, D. Y. Park, N. Agarwal, et al., “The promise and illusion of continuous, cuffless blood pressure monitoring,” *Current Cardiology Reports*, vol. 25, pp. 1139–1149, 2023.

[8] A. Garrett, A. Perez, R. Ayalon, et al., “Optical methods for cuffless blood pressure measurements,” *Biophotonics Discovery*, vol. 3, no. 1, 010901, 2026.

[9] R. Pal, J. Le, T. Wingert, et al., “From cuffs to code: Machine learning in non-invasive blood pressure monitoring,” *Anaesthesia Critical Care & Pain Medicine*, vol. 45, 101655, 2026.

[10] W. Wang, P. Mohseni, K. L. Kilgore, and L. Najafizadeh, “PulseDB: A large, cleaned dataset based on MIMIC-III and VitalDB for benchmarking cuff-less blood pressure estimation methods,” *Frontiers in Digital Health*, vol. 4, 1090854, 2023.

[11] I. Sanches, V. V. Gomes, C. Caetano, L. S. B. Cabrera, V. H. Cene, T. Beltrame, W. Lee, S. Baek, and O. A. B. Penatti, “MIMIC-BP: A curated dataset for blood pressure estimation,” *Scientific Data*, vol. 11, 1233, 2024, doi: 10.1038/s41597-024-04041-1.

[12] B. Moody, G. Moody, M. Villarroel, G. D. Clifford, and I. Silva, “MIMIC-III Waveform Database Matched Subset (version 1.0),” PhysioNet, 2020, doi: 10.13026/c2294b.